

Seqs Zusammenfassung

October 27, 2023

Contents

1	Suffix Arrays	2
1.1	Skew Algorithmus	2

1 Suffix Arrays

Sei $S = c_1c_2\dots c_n$ ein String. der i -te Suffix S_i ist definiert als der String $c_ic_{i+1}\dots c_n$. Ein Suffix Array nimmt die Menge aller n Suffixe und sortiert sie lexikographisch. Dafür ist eine Ordnung $<$ auf dem Alphabet Σ gegeben. Die naive Implementierung, die Substrings anhand ihrer ersten Character vergleicht, hat eine Laufzeit von $\mathcal{O}(n^2)$

1.1 Skew Algorithmus

Dieser ist ein Beispiel für einen linear-Zeit Algorithmus. Dieser wird im Folgenden am Beispiel $S = \text{ctaataatg}$ erklärt.

Schritt 1. Als erstes teilt der Algorithmus den String S in zwei Teile. Sei S_i der Substring beginnend an der Stelle i . Man definiert die Menge $S_L = \{S_i : i \bmod 3 \neq 1\}$ und $S_R = \{S_i : i \bmod 3 = 1\}$. Im Beispiel besteht S_L aus

- taataatg
- aataatg
- atg
- tg
- g

und S_R aus

- ctaataatg
- ataataatg
- atg

Die Suffixmenge von S_L wird mittels Radixsort rekursiv in linearer Zeit sortiert, dabei wird nur bezüglich der ersten drei Stellen aller Suffixe sortiert. Dadurch erhält man

- aat (S_3)
- aat (S_6)
- g\$\$ (S_9)
- taa (S_2)
- taa (S_5)

- $\text{tg\$}(S_8)$

Wären nun alle dieser Tripel echt verschieden, so wäre diese Liste bereits total sortiert, was in diesem Beispiel aber nicht der Fall ist. Die Tripel werden anschließend von oben nach unten nummeriert, wobei gleiche Tripel die gleiche Nummer erhalten. Diese werden als lexikografische Namen bezeichnet. Man definiert \overline{S} als der String der lexikografischen Namen der Substrings S_i mit $i \bmod 3 = 2$ konkateniert mit dem String der lexikografischen Namen der Substrings S_i mit $i \bmod 3 = 0$. Im Beispiel ist $\overline{S} = 334112$. Auf \overline{S} wird der Algorithmus rekursiv angewandt. Von \overline{S} erhalten wir die Suffixe

1. 334112
2. 34112
3. 4112
4. 112
5. 12
6. 2

Diese Liste wird im Sinne eines Suffixarrays sortiert, wodurch man

- 112
- 12
- 2
- 334112
- 34112
- 4112

erhält. Für jeden dieser Suffixe erhält man einen dazugehörigen Suffix vom ursprünglichen String S und seine Position in i in S . In der Tat erhält man die Zuordnungen: $\overline{S}_1 \equiv S_2$, $\overline{S}_2 \equiv s_5$, $\overline{S}_3 \equiv S_8$, ...

Im Allgemeinen gilt $\overline{S}_{\frac{i+1}{3}} \equiv S_i$ wenn $i = 3 \bmod 2$. Für $i = 0 \bmod 3$ hingegen gilt $\overline{S}_{\frac{n+i}{3}} \equiv S_i$. Dafür wird die Notation

$$\tau(i) = \begin{cases} \frac{i+1}{3}, & i = 2 \bmod 3 \\ \frac{n+i}{3}, & i = 0 \bmod 3 \end{cases}$$

Da wir aber die Richtung von \overline{S} zu S benötigen, brauchen wir die Umkehrabbildung von τ :

$$\tau^{-1}(j) = \begin{cases} 3j - 1, & 1 \leq j \leq \frac{n}{3} \\ 3j - n, & \frac{n}{3} < j \leq \frac{2n}{3} \end{cases}$$

Mittels τ^{-1} können nun die Suffixe von \overline{S} in jene von S umgerechnet werden, die dadurch sortiert sind. Schritt 2: In diesem Teil müssen die Suffixe in S_R sortiert werden. In diesem Schritt wird jeder Suffix von seinem Anfangsbuchstaben getrennt. Man erhält

- $S_1 = cS_2$
- $S_4 = aS_5$
- $S_7 = aS_8$

Wendet man nun Radixsort auf die ersten Buchstaben an, so werden diese Strings automatisch sortiert.

Schritt 3: In diesem Schritt werden die beiden Sublisten wieder zu einem Suffixarray zusammengefügt. Wenn das in der naiven Merge-Sort Implementierung durchgeführt wird, so würde das in quadratischer Laufzeit resultieren. Deswegen wird wieder die Strategie von Schritt 2 verwendet; die Liste S_R wird wieder aufgespalten in erste Buchstaben und Suffixe von S_L . Dadurch sind die beiden Suffixe aber nicht zwingend in der selben Gruppe, weswegen auch noch der zweite Buchstabe abgespalten werden kann. Der Merge Teil kann nun zuerst auf Basis der ersten beiden Buchstaben entschieden werden, außer wenn die beiden Buchstaben der zu vergleichenden Suffixe gleich sind. Dieses Verfahren funktioniert für Substrings S_i aus S_L mit $i \equiv 0 \pmod{3}$. Für Substrings S_i aus S_L mit $i \equiv 2 \pmod{3}$ hingegen würde die abgespaltenen Suffixe wieder in verschiedenen Listen liegen. Deshalb wird in diesem Fall nur ein Buchstabe abgespalten.

Der Vergleich der beiden abgespaltenen Suffixe funktioniert aber nur in linearer Zeit. Deswegen wird hierfür das sogenannte inverse Suffixarray eingeführt.

Definition 1.1.1 (inverses Suffixarray (ISA)). Für ein Suffixarray SA mit $k \rightarrow SA[k]$ ist das inverse Suffixarray definiert durch $ISA[SA[k]] = k$.

Allgemein gilt dann $S_i < S_j \Leftrightarrow ISA[\tau(i)] < ISA[\tau(j)]$.